

Meta-analysis in Medical Research

Haewon Lee

2025년 9월 14일

차 례

차 례	2
1 필요성과 목적	5
2 메타분석의 개념 Gene Glass	7
3 Inverse χ^2 method	10
4 효과크기	12
4.1 기본 개념	12


4.2	Example	14
4.3	효과크기의 분산	17
4.4	제한된 데이터로 효과크기 계산하는 방법	20
5	Example 연속형 데이터의 효과크기 계산 및 메타분석	21
6	연구간의 차이 - 이질성	28
7	출간오류	32
8	다양한 데이터 타입의 효과크기	35
9	효과크기의 전환	39
10	생존분석 데이터	44
10.1	Hazard Ratio	44
10.2	Material	45
10.3	Risk of Bias	48
10.4	Forest plot	51
10.5	Publication Bias	52
10.6	Subgroup analysis	53
11	Network meta-analysis	58
11.1	Introduction	58
11.2	기본적인 계산방법	63

11.3 네트워크 메타분석 케이스	67
11.4 Bayesian inference	75
12 결론	83
참고 문헌	84

1 필요성과 목적

필요성과 목적

- meta- 라는 어원은 그리스어에서 going above, after 또는 beyond를 나타냄
: 선행연구들의 결과를 수렴하여 결과를 내는 것
- 필요성 - 서로 상반된 결과를 보이는 논문들의 존재
- 선행연구를 전부 모아서 객관적이며 신뢰성이 있는 결론 도출의 필요성
narrative review (전문가들에 의한 정성평가) vs systemic review (객관적이고 재현가능한 정량평가)
- 개별 연구들의 결과를 계량화
- 통합된 효과크기로 제시
- 문제나 가설에 대한 넓은 범위를 다루게 됨
- 객관적 : 결론을 내리기 위해 많은 사람들의 리뷰가 필요없음



근거 수준 피라미드(The levels of evidence pyramid)

근거의 질과 양을 모두 시각적으로 보여주는
방법으로 피라미드 아래로 내려갈수록 근거의 질은
감소하는 반면, 그 양은 증가

*Systemic Review 중에서 meta-analysis가 최상층
[The Open Dentistry Journal, 2012, 6, 31-40](#)

2 메타분석의 개념 Gene Glass

메타분석의 개념

- 1차분석 : 연구에서 얻은 원자료를 분석
- 2차분석 : 1차분석에서 제기되었던 연구질문을 더 나은 통계적 방법으로 분석
- 메타분석 : 분석한 것들을 다시 분석
 - 수량적인 분석 - 수많은 연구결과를 함축성 있게 연구하고 요약된 통계
 - 효과크기를 계산하기 위해 상이한 결과를 모음 (주관적 배제는 금지)
 - 다양한 연구결과를 통합하여 효과크기로 결론을 일반화 (단편적인 작은 차이는 무시됨)
- "다른 통계방법으로는 결론을 내릴 수 없는 연구에 적절하다." Glass


간략한 역사

- 최초의 메타분석은 장티푸스 예방 접종과 사망률 간의 상관 관계에 대한 5건의 연구 데이터를 분석한 Pearson(1904)의 연구
- 1932년 피셔는 검정의 p 값의 자연 로그에 -2로 곱한 값이 정확히 자유도가 2인 카이 제곱 분포를 따른다는 것을 발견

$$\chi^2_{2m} = -2 \sum_{j=1}^m \ln(p_i)$$

- 이 방법은 피셔의 역 카이 제곱 방법으로 알려져 있다. 이러한 유형의 메타 분석은 효과 측정 없이 p 값이 존재하는 연구나, 서로 다른 연구의 설계 또는 치료 유형이 너무 달라서 누적 효과를 평가하는 것이 옳지 않을 때 적용
 - 이 방법은 서로 다른 연구의 값이 피험자 수, 변동성등의 특징에 따라 가중되지 않고, 효과의 크기에 대한 아이디어를 얻을 수 없으며 반대 결과가 있는 연구를 통합하는 것은 불가능
- Archie Cochrane 1974 ~ 1985년동안 3,500 개의 문헌을 요약하여 600 개의 체계적 고찰을 완성 1992년 영국에서는 그의 사후에 Cochrane center 설립
- 1976 Gene Glass가 철학적 개념으로 이 용어를 처음으로 사용함

Professor Archibald Cochrane (1909-1988) is best known for his influential 1972 book, *Effectiveness and Efficiency: Random Reflections on Health Services*.



[https:// www.cochrane.org/ about-us/our-story/our-name-and-logo](https://www.cochrane.org/about-us/our-story/our-name-and-logo)

Logo of Cochrane Center

외부에서 두 개의 'C' 모양이 이루는 원은 전 세계적인 협력을 나타냅니다. 원 안에 있는 선들은 상징적인 체계적 문헌고찰(systematic review)의 요약 결과를 보여줍니다. 각각의 수평선은 개별 연구의 결과를 나타내며, 다이아몬드는 그 연구들을 통합한 결과, 즉 해당 치료법이 효과적인지 아니면 해로운지에 대한 저희의 최상의 추정치를 의미합니다. 다이아몬드가 '차이 없음'을 나타내는 수직선보다 명확하게 왼쪽에 위치하므로, 이 근거는 해당 치료법이 유익하다는 것을 나타냅니다. 이러한 표현 방식을 'forest plot'이라고 부릅니다.

로고 안의 이 forest plot은 체계적 문헌고찰이 보건 의료를 개선할 수 있는 잠재력을 보여주는 한 가지 사례입니다. 이는 곧 조산할 위험이 있는 여성에게 투여된 코르티코스테로이드가 신생아의 생명을 구할 수 있다는 것을 보여줍니다.

코르티코스테로이드의 유익함을 보여주는 여러 임상시험에도 불구하고, 산부인과 의사들 사이에서 이 치료법의 채택은 더뎠습니다. 이 **체계적 문헌고찰**은 해당 치료법의 사용을 늘리는 데 큰 영향력을 미쳤습니다. 이 간단한 중재는 아마도 수천 명의 조산아들의 생명을 구했을 것입니다.

3 Inverse χ^2 method

*Fissure*의 inverse χ^2 -메타분석



- 만약 세가지 독립적인 연구가 동일한 귀무가설로 p 값을 구했다고 가정하고 각각의 p 값 $(p_1, p_2, p_3) = (0.05, 0.01, 0.10)$ 라고 하자

$$\chi^2 = -2 \sum_{i=1}^3 \ln(p_i)$$

- $\chi^2 = -2 \times (\ln 0.05 + \ln 0.01 + \ln 0.1) = 19.808$ and $df = 2k = 6$
- χ^2 분포에서 19.808과 자유도 6에 해당되는 p 값을 구하면 약 0.003이 된다.
- 오로지 p 값만 있으면 되므로 간단함
- p 값은 0에서 1사이의 균등분포($p \sim U(0, 1)$) $-2\ln(p)$ 의 값은 자유도가 2인 χ^2_2 분포를 따름 $-2\ln(p)$ 의 누적함수가 χ^2_2 의 누적함수와 정확하게 일치함 $\rightarrow$ 여러개의 p 값을 합치면 자유도가 2씩 증가함 따라서 $\sum_{i=1}^k -2\ln(p_i) \sim \chi^2_{2k}$

χ^2 -분포

- 만약 $Z_1, \dots, Z_k$ 가 독립적인 정규분포일때 그들의 제곱들의 합 $X = \sum_{i=1}^k Z_i^2$
- 이 X 의 값의 분포를 χ^2 분포라고 함. 이것을 $X \sim \chi_k^2$ 로 표현: k 는 자유도
- 확률 밀도함수는 다음과 같다. ($x \geq 0, \mu = k, \sigma^2 = 2k$): Probability Density Function $f(x) = \frac{x^{k/2-1}e^{-x/2}}{2^{k/2}\Gamma(k/2)}$



4 효과크기



4.1 기본 개념

효과크기(ES)의 개념

- 여러개의 연구결과를 양적으로 통합하는데 각각의 연구결과의 효과의 크기가 다름
- 실험집단의 평균값에서 비교집단의 평균값을 뺀 값을 비교집단 (혹은 두 집단)의 표준편차 값으로 나눈 값을 의미 (Cohen's d) 또는 두 연속변수간의 상관계수 (Pearson's r) (기타: η^2 , R^2 , ..)
- 통계적으로 의미가 있어도 집단간의 차이가 없다면 효과의 차이도 적다.
- 표본수가 많으면 효과크기가 작아도 p -값이 0.05 이하가 될 수 있고, 그 반대 현상도 있음
- 통계적 유의성 검정을 통한 리뷰방식은 효과의 방향성과 크기를 제시해주지 못함: 대안으로 등장

효과크기(ES)의 의미와 장점

- 효과 크기가 0이라는 의미는 비교하려는 집단 사이의 평균이 동일하다는 의미
- 평균을 비교할 경우 효과크기가 1.96 이라면 정규분포의 Z 값과 같은 의미이므로 실험군의 평균은 대조군의 분포에서 상위 5%에 해당함을 의미
- 연구결과의 해석을 이분법적인 방법이 아닌 연속선상에서 할 수 있게 해준다.
- 효과 크기는 표본수에 따라서 변하지 않음
- 서로 다른 통계적 방법을 사용한 연구결과들을 수량적으로 통합하는 메타분석을 시행해서 공통 척도로 표현할 수 있음



4.2 Example

연속형 데이터에서 *Cohen's d* 계산 예시

- 새로운 교육 방법이 학생들의 시험 점수를 향상시키는지 알아보기 위해 독립적으로 수행된 두 개의 연구(A, B)가 있다고 가정

연구	그룹	참여자수 (N)	평균 (M)	표준편차 (SD)
A	실험군	50	85	10
A	통제군	50	80	12
B	실험군	40	78	8
B	통제군	40	75	7

- 합동표준편차 (SD_{pooled})

$$SD_{pooled\ A} = \sqrt{\frac{49 \times 10^2 + 49 \times 12^2}{49 + 49}} \approx 11.05, \quad SD_{pooled\ B} = \sqrt{\frac{39 \times 8^2 + 39 \times 7^2}{39 + 39}} \approx 7.52$$

- Cohen's d

$$d = \frac{M_{exp} - M_{ctrl}}{SD_{pooled}}, \quad d_A = \frac{85 - 80}{11.5} \approx 0.45, \quad d_B = \frac{78 - 75}{7.52} \approx 0.40$$

- cohen's d는 그냥 평균을 내면 안되고 분산을 먼저 구해야 함

$$v = \frac{N_{exp} + N_{ctrl}}{N_{exp} \times N_{ctrl}} + \frac{d^2}{2(N_{exp} + N_{ctrl})}, \quad v_A = \frac{50 + 50}{50 \times 50} + \frac{0.45^2}{2(50 + 50)} \approx 0.041, \quad v_B \approx 0.051$$

- 연구의 가중치는 분산의 역수 $w = 1/v$, $w_A \approx 24.39$, $w_B \approx 19.61$

- 종합 효과트기 (Combined d)

$$d_{combined} = \frac{\sum(w_i \times d_i)}{\sum w_i} = \frac{24.39 \times 0.45 + 19.61 \times 0.40}{24.39 + 19.61} \approx 0.42$$

Cohen's d vs Hedges' g 차이점

- Hedges 등이 개발한 교정방법 : Hedges 등은 표본수가 작을 경우 Cohen의 방법이 실제 값보다 부풀려졌다는 것을 알게 되어 이를 교정하는 방법을 발표함 (Statistical Methods for Meta-Analysis, Hedges & Olkin, 1985)
- Cohen's d 에서 Hedges' g 를 계산하는 방법

$$g = d \times J(df) = d \times \left(\frac{\Gamma(df/2)}{\sqrt{df/2} \Gamma((df-1)/2)} \right)$$

$$\Gamma(z) = \int_0^{\infty} e^{-t} t^{z-1} dt, \quad df = n_1 + n_2 - 2$$

- Hedges' g^* 간단한 계산법 : $n \geq 10$ 인 경우에는 오차가 매우 작다는 것을 입증 (df=2 일 때 0.007, 10 이상일 때 0.003 이하, 클수록 차이가 작아짐)

$$g^* = d \times \left(1 - \frac{3}{4df-1} \right)$$

- 현재는 Hedges' g^* 를 일반적으로 사용함

4.3 효과크기의 분산

*Cohen's d*의 분산을 구하는 방법

- Cohen's d : $d = \frac{\bar{X}_1 - \bar{X}_2}{S_{pooled}}$
- 분자 ($\bar{X}_1 - \bar{X}_2$)의 불확실성 계산: 분모의 S_{pooled} 를 모집단의 표준편차 σ 와 같다고 가정하고 분자만의 분산을 구한다

$$\text{Var}(d) = \text{Var}\left(\frac{\bar{X}_1 - \bar{X}_2}{\sigma}\right) = \frac{1}{\sigma^2} \text{Var}(\bar{X}_1 - \bar{X}_2) = \frac{1}{\sigma^2} (\text{Var}(\bar{X}_1) + \text{Var}(\bar{X}_2))$$

그런데 $\text{Var}(\bar{X}_1)$ 의 값은 $\frac{\sigma^2}{n_1}$ 인 관계이므로 $\text{Var}(d) = \frac{1}{n_1} + \frac{1}{n_2}$

- 통합표준편차 S_{pooled} 의 분포는 χ^2 분포를 따름 $\rightarrow$ 여기에서 통합분산의 분산은 다음과 같이 유도할 수 있다. (t 분포라고 가정할 때)

$$\text{Var}(S_{pooled}^2) \approx \frac{2(\sigma^2)^2}{n_1 + n_2 - 2}$$

- 여기에 Delta Method 적용

$$\text{Var}(g(X)) \approx [g'(E[X])]^2 \times \text{Var}(X)$$

다음과 같이 대입 $X \leftarrow S_p^2$, $g(X) \leftarrow \sqrt{X} = S_p$, $g'(X) \leftarrow \frac{1}{2\sqrt{X}} = \frac{1}{2\sigma}$, $E(S_p^2) = \sigma^2$

$$\text{Var}(S_p) \approx \left(\frac{1}{2\sigma}\right)^2 \times \text{Var}(S_p^2) = \frac{\sigma^2}{2(n_1 + n_2 - 2)}$$

- 위에서 유도한 식 $\text{Var}(s_p) \approx \frac{\sigma^2}{2 \cdot df}$ 에는 우리가 알 수 없는 모집단 분산 σ^2 가 있습니다. 따라서 이것을 가장 좋은 추정치인 표본의 통합 분산 S_p^2 으로 대체합니다. $\text{Var}(S_p) \approx \frac{S_p^2}{2(n_1 + n_2 - 2)}$
- 분모의 S_{pooled} 를 모집단의 표준편차 σ 와 같다고 가정하고 구한 분자 $(\bar{X}_1 - \bar{X}_2)$ 의 분산과 S_{pooled} 의 분산을 더하면 Cohen's d 의 분산이 된다.

$$\text{Var}(d) = \frac{N_{exp} + N_{ctrl}}{N_{exp} \times N_{ctrl}} + \frac{d^2}{2(N_{exp} + N_{ctrl})}$$

*delta method*란?

- $\text{Var}(g(X)) \approx [g'(E[X])]^2 \times \text{Var}(X)$
- 확률 변수 X 의 함수 $g(X)$ 대한 Taylor series $g(X) \approx g(\mu) + g'(\mu)(X - \mu) + \dots$
- 양변의 기대값을 구함 $E[g(X)] \approx E[g(\mu) + g'(\mu)(X - \mu)]$
여기서 기대값은 선형성을 가지므로 $E[g(X)] \approx g(\mu) + g'(\mu) \times E[(X - \mu)]$
- $E[X - \mu] = E[X] - \mu = \mu - \mu = 0$ 이므로 $E[g(X)] \approx g(\mu) = g(E[X])$
- Taylor series 양변에 분산을 취하면 $\text{Var}(g(X)) \approx \text{Var}(g(\mu) + g'(\mu)(X - \mu))$ 여기서 $g(\mu)$ 는 상수
분산의 성질 $\text{Var}(a + bX) = b^2 \text{Var}(X)$ 을 이용하여 정리하면 $\text{Var}(g(X)) \approx \text{Var}(g'(\mu) \times (X - \mu)) = [g'(E[X])]^2 \times \text{Var}(X)$
- Example) 평균이 μ , 표준편차가 σ 인 분포 X 가 있을 때 $\ln(X)$ 의 분산은?
 $g(X) = \ln(X), g'(X) = \frac{1}{X}$ 이므로 $\text{Var}(g(X)) \approx [g'(E[X])]^2 \times \text{Var}(X) = \left(\frac{1}{\mu}\right)^2 \sigma^2 = \frac{\sigma^2}{\mu^2}$

4.4 제한된 데이터로 효과크기 계산하는 방법

 t , F 값으로 구하는 방법

- 평균이나 표준편차 데이터가 불명하고 $t(df)$ 의 형태로 결과가 제시된 경우 : $d = t \sqrt{\frac{n_1 + n_2}{n_1 n_2}}$
- p 값만 제시된 경우 : $t(df)$ with $p = 0.01 \rightarrow d = t_{\alpha=0.01} \sqrt{\frac{n_1 + n_2}{n_1 n_2}}$
- ANOVA test 후 F 값만 주어진 경우 $d = \sqrt{\frac{F(n_1+n_2)}{n_1 n_2}}$


5 Example 연속형 데이터의 효과크기 계산 및 메타분석

sample data (연속형): 심성률 ”의학·보건학 연구자를 위한 R 메타분석”

study	n1	m1	s1	n2	m2	s2	md	sd	se	cohen_d	cohen_se	g
Mitsui2003	7	23.20	4.20	5	39.00	7.40	-15.80	5.699825	3.337	-2.7720151	0.8142645	1
Mitsui2005a	12	28.20	0.90	11	35.90	1.40	-7.70	1.165169	0.486	-6.6084828	1.0600164	1
Mitsui2005b	8	27.90	2.00	10	33.40	1.20	-5.50	1.600000	0.759	-3.4375000	0.7437967	1
Mitsui2011	10	27.90	2.00	9	36.10	2.70	-8.20	2.355469	1.082	-3.4812597	0.7280361	1
Telmeltas2009_1	10	43.40	5.71	5	61.80	9.41	-18.40	7.058161	3.866	-2.6069113	0.7256259	0
Telmeltas2009_2	9	53.10	7.88	5	61.80	9.41	-8.70	8.420944	4.697	-1.0331383	0.5909582	0
WBPark2010_1	9	9.70	4.11	11	9.60	4.20	0.10	4.160240	1.870	0.0240371	0.4494826	1
WBPark2010_2	6	10.33	4.50	9	8.11	7.39	2.22	6.433965	3.391	0.3450438	0.5307978	1
YHu2012	8	33.82	3.79	8	40.74	3.97	-6.92	3.881044	1.941	-1.7830255	0.5910578	0
YingJin2011_1	9	36.21	1.72	10	42.32	4.07	-6.11	3.187764	1.465	-1.9167038	0.5547872	1
YingJin2011_2	6	37.21	2.04	10	42.32	4.07	-5.11	3.483554	1.799	-1.4668926	0.5778491	1

```
ma_con <- metacont( n1,m1,s1,n2,m2,s2,sm="SMD",method.smd="Hedges", subgroup = g, data=data_con)
```

Forest Plot : summary of meta-analysis



Number of studies: $k = 11$

Number of observations: $o = 187$ ($o.e = 94$, $o.c = 93$)

SMD	95%-CI	z	p-value
Common effect model	-1.4610	[-1.8356; -1.0865]	-7.65 < 0.0001
Random effects model	-1.9957	[-2.9961; -0.9953]	-3.91 < 0.0001

Quantifying heterogeneity (with 95%-CIs):

$\tau^2 = 2.3819$ [0.9367; 9.6341]; $\tau = 1.5433$ [0.9678; 3.1039]

$I^2 = 82.8\%$ [70.5%; 89.9%]; $H = 2.41$ [1.84; 3.15]

Test of heterogeneity:

Q d.f. p-value

57.98 10 < 0.0001

Results for subgroups (common effect model):

k	SMD	95%-CI	Q	I^2
$g = 1$	8 -1.4123	[-1.8497; -0.9750]	55.37	87.4%
$g = 0$	3 -1.5949	[-2.3203; -0.8696]	2.43	17.6%

Test for subgroup differences (common effect model):

Q d.f. p-value

Between groups 0.18 1 0.6726

Within groups 57.80 9 < 0.0001

Results for subgroups (random effects model):

k	SMD	95%-CI	tau ²	tau
---	-----	--------	------------------	-----

g = 1	8	-2.1672 [-3.5738; -0.7606]	3.6058	1.8989
-------	---	----------------------------	--------	--------

g = 0	3	-1.6076 [-2.3911; -0.8242]	0.0662	0.2573
-------	---	----------------------------	--------	--------

Test for subgroup differences (random effects model):


Q d.f. p-value

Between groups 0.46 1 0.4958

Details of meta-analysis methods:

- Inverse variance method
- Restricted maximum-likelihood estimator for tau²
- Q-Profile method for confidence interval of tau² and tau
- Calculation of I² based on Q
- Hedges' g (bias corrected standardised mean difference; using exact formulae)

Meta regression : bubble plot



출판편향 통계적 검정

```
> ma_con %>% metabias(method.bias = "linreg")  
Linear regression test of funnel plot asymmetry
```

Test result: $t = -6.92$, $df = 9$, $p\text{-value} < 0.0001$
Bias estimate: -9.3267 ($SE = 1.3478$)

Details:


- multiplicative residual heterogeneity variance ($\tau^2 = 1.0192$)
- predictor: standard error
- weight: inverse variance
- reference: Egger et al. (1997), BMJ

```
> ma_con %>% metabias(method.bias = "rank")  
Rank correlation test of funnel plot asymmetry
```

Test result: $z = -3.04$, $p\text{-value} = 0.0024$
Bias estimate: -39.0000 ($SE = 12.8452$)

Reference: Begg & Mazumdar (1993), Biometrics

Publication bias : Funnel plot



6 연구간의 차이 - 이질성

Fixed(Common) effect model vs Random effect model

- Fixed effect model은 추정된 효과가 단일 동질적인 모집단에서 나온다고 가정한다. 따라서 공통된 효과를 측정하여 "통합된 공통 효과 크기"로 해석한다.
- Random effect model은 연구 효과 추정치가 변동성이 더 클 수 있다는 사실을 고려한다. 따라서 각 연구마다 자체적인 효과가 있고 이 효과들이 특정 분포를 이룬다. 연구간 분산이 존재한다고 본다. → 신뢰구간이 더 넓다. 표본크기가 클수록 더 큰 가중치를 주지만 그 차이가 적다.
"여러 효과들의 평균적인 크기"로 해석한다. 대신 유사한 연구들에도 결과를 일반화할 수 있다.
- Random effect model의 차이점은 연구내의 분산은 똑같으나 연구간의 분산이라는 추가적인 오차 요소를 함께 고려한다는 점 : Fixed effect model의 연구가중치는 $w_{iFE} = \frac{1}{v_i}$ 인데 이때의 분산 v_i 에 연구간 분산 τ^2 를 더하여 $v_i^* = v_i + \tau^2$ 이 분산이 되고, 가중치는 $w_{iRE} = \frac{1}{v_i + \tau^2}$ 가 된다.

τ^2 in Random effect model : DerSimonian-Laird 방법

- Cochran's Q 통계량은 각 연구 결과가 전체 평균(고정 효과 모델 기준)에서 얼마나 떨어져 있는지를 가중치를 주어 합산한 값으로, 연구들 간의 '관찰된 총 변동량'을 의미 $Q = \sum w_i(\theta_i - \theta_{FE})^2$ 여기서 θ_i = 개별 연구 i의 효과 크기, θ_{FE} = 고정 효과 모델로 계산한 전체 평균 효과 크기, w_i = 개별 연구 i의 고정 효과 가중치
- Cochran's Q 통계량은 각 연구 결과가 이질성이 전혀 없을 경우 자유도 $df = k - 1$ 과 같다.
- 가중치의 분포를 보정하기 위한 상수를 계산 $C = \sum w_i - \frac{\sum w_i^2}{\sum w_i}$
- $\tau^2 = \frac{Q - df}{C}$
- $Q - df$ 는 단순오차를 넘어서는 변동량을 의미이고 음수가 되면 0으로 설정한다.
- DerSimonian-Laird 방법은 고전적이고 이해하기 쉽지만, 연구 수가 적을 때 추정치가 부정확할 수 있다는 단점이 있다.
- 제한적 최대우도법 (Restricted Maximum Likelihood, REML) 이나 파울-맨델 추정량 (Paule-Mandel, PM) 으로 계산하는 방법을 더 많이 사용함

τ^2 제한적 최대우도법 (*Restricted Maximum Likelihood, REML*)

- τ^2 를 초기값 0 또는 위의 DL 방법으로 얻은 값으로 설정한 다음 최적의 τ^2 를 찾아가는 방법을 사용한다.
- 일반 최대우도법(ML): 우리가 가진 데이터가 나타날 확률(우도, Likelihood)을 가장 높이는 파라미터(평균 효과 μ 와 연구 간 분산 τ^2) 를 동시에 찾는 방법인데 이렇게 하면 작은 τ^2 를 얻는 효과가 있음
- 제한적 최대우도법(REML)은 이 편향을 해결하기 위해 고안되었는데 평균 효과(μ)의 불확실성을 계산 과정에서 제한하고, 순수하게 분산(τ^2)을 추정하는 데에만 집중
- 우도 함수 $L(\tau^2)$ 최대치를 얻기 위해서는 미분한 다음 기울기가 0이 되는 점을 Newton-Raphson method와 같은 근사치방법으로 찾는다.
- $\theta_i | \beta_i \sim N(\beta_i, v_i), \quad \beta_i \sim N(\mu, \tau^2) \rightarrow \quad \theta_i \sim N(\mu, v_i + \tau^2), \quad \theta_i | \beta_i \text{ 는 } \beta_i \text{ 가 주어졌을 때의 조건부 } \theta_i$
- $\ln L(\mu, \tau^2) = C - \frac{1}{2} \sum_{i=1}^k \left(\ln(v_i + \tau^2) + \frac{(\theta_i - \mu)^2}{v_i + \tau^2} \right)$

이질성 통계치 τ^2 및 I^2

- Q값의 의미: $Q = \sum w_i(\theta_i - \theta_{FE})^2$ 각 효과 크기들의 관찰된 분산에 가중치를 곱한 값
- $\tau^2 = \frac{Q - df}{C}$ C는 scaling factor τ^2 를 효과크기와 같은 표준화 단위로 만드는 인자 $C = \sum w_i - \frac{\sum w_i^2}{\sum w_i}$
- I^2 총 분산에 대한 실제 분산의 비율을 나타내며 절대값이 아닌 비율 (%) $I^2 = \frac{Q - df}{Q} \times 100\%$
- I^2 값이 25% 이하이면 이질성이 작다고 판단하고 75% 이상이면 매우 크다고 해석한다. 이질성 통계치는 고정효과에 서만 계산이 가능함
- 이질성의 원인에 대해서는 다양한 해석이 가능하다.

7 출간오류

publication bias : small-study effect

- 표본크기가 작은 연구들이 상대적으로 큰 효과크기를 보이는 경향이 있다. 표본이 큰 연구는 통계적 유의성이 작아도 출간되며 표본이 작은 연구는 출간되지 않을 가능성이 높지만 효과크기가 크다면 출간될 가능성이 있다.
- 표본의 크기와 효과크기의 관계를 보여주는 방법은 funnel plot : 수평축(x 축)에 효과 크기를, 수직축(y 축)에 표준오차를 보여준다. 대각선은 효과크기의 95% 신뢰구간을 나타낸다.
- 비대칭적인 분포이면 small-study effect가 있다고 해석한다.
- Egger's regression test : 효과크기 / 효과크기의 표준오차 (y 축 종속변수), $1/\text{표본크기의 표준오차}$ (x 축 독립변수)로 하여 단순 선형회귀분석을 수행한다. 이때 회귀식의 y 절편이 0에 가까우면 대칭
- Begg and Mazumdar Test : 출판 편향이 없다면, 연구의 결과(효과 크기)와 연구의 크기(분산이 클수록 연구 크기가 작음) 사이에는 아무런 관련이 없어야 한다. 연구들을 효과 크기 순으로 줄 세운 것과 분산(또는 표준오차) 순으로 줄 세운 것이 서로 관련이 있는지를 켄달의 순위 상관계수 타우(Kendall's rank correlation coefficient,)를 통해 검증

publication bias : Klein's method

- '출판 편향이 존재한다면, 메타 분석 결과를 무효화하는 데 얼마나 많은 null 또는 음성 연구가 필요한가?'라는 질문에 답한다.
- Number Needed to Treat (NNT): 통합된 상대위험도를 이용하여 Absolute Risk Reduction을 구하고 이를 역수로 취함. (example) $RR=0.6$, Control Event rate*(통제군의 이벤트 발생률) = 0.2 라고 하면 $ARR = 0.2 - (0.2 \times 0.6) = 0.08$, $NNT = 12.5$
- Trim and fill : 깔때기 그림에서 비대칭을 유발하는, 한쪽에만 치우친 작은 연구들을 일시적으로 제거, 제거된 연구들과 대칭되는 위치에 누락되었을 것으로 추정되는 가상의 연구들을 생성하여 깔때기 그림을 채움 → 원래의 연구와 가상으로 채워진 연구를 모두 포함하여 편향이 보정된 새로운 통합 효과 크기를 다시 계산 → NNT 다시 계산
- 기존의 NNT 12.5 → 보정된 NNT 30 인 경우 → 기존의 분석결과로는 12.5명을 치료하면 1명의 나쁜 결과를 막을 수 있는데 보정된 결과에서는 30명을 치료하면 1명의 나쁜 결과를 막을 수 있다. → 실제보다 낙관적인 편향

누적메타분석

- 누적 메타 분석은 문헌에 발표된 데이터를 역사적으로 평가할 수 있도록 해주며 표준 메타 분석으로는 불가능한 평가를 가능하게 한다
- 임상 시험은 출판 연도 순으로 나열해야 한다. 첫 번째 OR은 시간 순서상 첫 번째 임상 시험을 나타내고, 두 번째는 첫 번째와 두 번째 임상 시험 간의 통합 OR 결과. 그 이후에는 계속 누적된 통합결과를 계산한다.
- 만약 메타분석의 결과가 좋은 치료효과를 보여주고 있다면 시간이 지날수록 누적환자수는 증가하면서 더 작은 신뢰구간을 갖는 결과를 보여줄 것이다. 또한 환자에게 위해가 가해질 수도 있는 임상실험연구를 추가로 더 할 필요가 없다는 것도 입증할 수 있다.

8 다양한 데이터 타입의 효과크기

효과크기 유형분류

- 일원적 연속형 데이터 : Cohen's d, Hedges' g
- 이원적 연속형 데이터 : 상관관계계수
- 이분형데이터 : 이벤트 발생비율 (Risk ratio), 승산비율 (Odds ratio), 이벤트 발생비율 차이 (Risk difference)

	질병(+)	질병(-)	Total
실험군	a	b	n_1
통제군	c	d	n_2

$$\text{Risk ratio} = \frac{\text{실험집단risk}}{\text{통제집단risk}} = \frac{a/n_1}{c/n_2} = \frac{a(c+d)}{c(a+b)}$$

$$\text{Odds ratio} = \frac{\text{실험집단odds}}{\text{통제집단odds}} = \frac{a/b}{c/d} = \frac{ad}{bc}$$

$$\text{Risk ratio} = \frac{\text{odds}}{1 + \text{odds}}, \text{Odds ratio} = \frac{\text{risk}}{1 - \text{risk}}$$

$$\text{Risk difference} = \frac{ab}{n_1^3} - \frac{cd}{n_2^3}$$

승산비 *Odds ratio* 효과크기

- 이분형데이터 : 승산비율 (Odds ratio)의 자연 log 값을 이용하여 효과크기를 계산한다.

	Event(+)	Event(-)	Total N	Odds ratio = $\frac{ad}{bc}$
• 실험군	a	b	n_1	LogOddsRatio = $\ln \frac{ad}{bc}$
통제군	c	d	n_2	$V_{\text{LogOddsRatio}} = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}$

- 가중치 $w_i = \frac{1}{V_{\text{LogOddsRatio}}}$
- 통합효과크기 $WY = \frac{\sum_{i=1}^k \ln(OR_i) \times w_i}{\sum w_i}$
- 연속형 데이터와의 차이점은 승산비율에 log를 취하여 $-\infty \sim +\infty$ 범위의 효과크기로 변형하여 계산하는 것이고 그 다음 절차는 연속변수와 같다.

상관관계데이터 효과크기

- 상관관계계수의 분산공식 : $\text{Var}(r) \approx \frac{(1 - \rho^2)^2}{n - 1} \rightarrow$ 여기에는 큰 문제가 있다. 우리가 알지 못하는 모집단의 상관관계계수 ρ 로부터 추정하는 것의 문제와 분포함수가 한쪽으로 크게 치우쳐지는 문제가 있어서 이를 해결하기 위해서는 모집단의 상관관계계수 ρ 와 무관하면서 정규분포에 가까운 변환이 필요함.
- 이 기준에 적합한 Fisher's Z로 전환하여 효과크기를 계산한다. $Z = 0.5 \times \ln \frac{1 + r}{1 - r}$
- Fisher's Z의 분산 $V_Z = \frac{1}{n - 3}$
- 가중치 $w_i = \frac{1}{V_Z} = n - 3$
- 통합효과크기는 Fisher's Z 값에 가중치분율을 곱하여 합한 값
- Fisher's Z에서 다시 상관계수로 전환할 때에는 $r = \frac{e^z - 1}{e^z + 1}$

Log Odds Ratio의 분산의 크기

- Log Odds Ratio의 값을 실험군과 통제군의 데이터로 표현하면,

$$\ln(OR) = \ln \left(\frac{\frac{a}{b}}{\frac{c}{d}} \right) = \ln \left(\frac{\frac{a}{a+b}}{1 - \frac{a}{a+b}} \right) - \ln \left(\frac{\frac{c}{c+d}}{1 - \frac{c}{c+d}} \right)$$

- 이 형태는 $\ln \frac{p}{1-p}$ 의 형태인데 이 분포함수의 분산은 delta method를 사용하면 $\frac{1}{np(1-p)}$ 가 됨.

$$\hat{p} = \frac{X}{n}, n \text{ 번의 시도 후 } X \text{ 번의 이벤트가 발생하는 비율의 분산은 } \text{Var}(\hat{p}) = \frac{p(1-p)}{n},$$


$$g(p) = \ln \left(\frac{p}{1-p} \right), g'(p) = \frac{1}{p(1-p)} \quad \therefore \text{Var}(g(\hat{p})) \approx \left(\frac{1}{p(1-p)} \right)^2 \times \frac{p(1-p)}{n} = \frac{1}{np(1-p)}$$

- 여기서 $p = \frac{a}{n_1}, 1-p = \frac{b}{n_1} \rightarrow \frac{1}{n_1 \frac{a}{n_1} \frac{b}{n_1}} = \frac{a+b}{ab} = \frac{1}{a} + \frac{1}{b}$

$$\text{같은 방법으로 } p = \frac{c}{n_2}, 1-p = \frac{d}{n_2} \text{인 경우를 적용하여 더하면 } V_{\text{LogOddsRatio}} = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}$$

9 효과크기의 전환

다양한 유형의 데이터로부터 계산된 효과 크기는 상호전환이 가능하다.



$$d \Leftrightarrow \text{LogOddsRatio}$$

$$\text{LogOddsRatio} = \ln \frac{ad}{bc}$$

$$\text{Cohen's } d = \frac{\bar{X}_1 - \bar{X}_2}{S_{pooled}}$$

$$V_{\text{LogOddsRatio}} = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}$$

$$\text{Var}(d) = \frac{N_1 + N_2}{N_1 \times N_2} + \frac{d^2}{2(N_1 + N_2)}$$

$$\text{LogOddsRatio} = d \times \frac{\pi}{\sqrt{3}}$$

$$\text{Cohen's } d = \text{LogOddsRatio} \times \frac{\sqrt{3}}{\pi}$$

$$V_{\text{LogOddsRatio}} = V_d \times \frac{\pi^2}{3}$$

$$\text{Var}(d) = V_{\text{LogOddsRatio}} \times \frac{3}{\pi^2}$$

$d \Leftrightarrow \text{correlation } r$

$$\text{Fisher's } Z = 0.5 \times \ln \frac{1+r}{1-r}, r = \frac{e^z - 1}{e^z + 1}$$

$$\text{Cohen's } d = \frac{\bar{X}_1 - \bar{X}_2}{S_{pooled}}$$

$$V_r = \frac{(1-r^2)^2}{n-1}, V_z = \frac{1}{n-3}$$

$$\text{Var}(d) = \frac{N_1 + N_2}{N_1 \times N_2} + \frac{d^2}{2(N_1 + N_2)}$$

$$r = \frac{d}{d^2 + a}, a = \frac{(n_1 + n_2)^2}{n_1 n_2}$$

$$\text{Cohen's } d = \frac{2r}{\sqrt{1-r^2}}$$

$$V_r = \frac{a^2 V_d}{(d^2 + a)^3}$$

$$\text{Var}(d) = \frac{4V_r}{(1-r^2)^3}$$

a 는 $n_1 \neq n_2$ 인 경우에 사용되는 교정인자

if n_1 and n_2 are unknown $a = 4$ i.e $n_1 = n_2$

LogOddsRatio의 분산과 정규분포의 분산의 차이

- Moment generating Function : 어떤 확률변수 X 의 MGF는 다음과 같이 정의 $M_X(t) = E[e^{tX}]$, $E[*]$: 기대값
그러면 MGF를 n 번 미분한 다음 $t = 0$ 을 대입하면 $E[X^n]$ 을 구할 수 있습니다. 즉 X 의 평균을 구할 때에는 MGF를 한번 미분하고 $t = 0$ 을 대입하면 됩니다. $E[X] = M'_X(0)$ 또한 같은 방법으로 $E[X^2] = M''_X(0)$
- 분산을 구할 때 이를 이용합니다. $\text{Var}(X) = E[X^2] - (E[X])^2 = M''_X(0) - [M'_X(0)]^2$
- 표준 로지스틱 분포의 확률밀도함수는 $f(x) = \frac{e^{-x}}{(1 + e^{-x})^2}$, MGF는 $M_X(t) = \int_{-\infty}^{\infty} e^{tx} \frac{e^{-x}}{(1 + e^{-x})^2} dx = \Gamma(1-t)\Gamma(1+t)$
- $E[X] = M'_X(0) = \Gamma(1)\Gamma(1)[- \psi(1) + \psi(1)]$, $E[X^2] = M''_X(0) = [\psi'(1) + \psi'(1)] = \frac{\pi^2}{3}$, trigamma 함수의 특수값 $\psi'(1) = \frac{\pi^2}{6}$ 을 이용함
- $\therefore \text{Var}(X) = E[X^2] - (E[X])^2 = M''_X(0) - [M'_X(0)]^2 = \frac{\pi^2}{3}$
- SMD의 분산은 1인데 로지스틱함수의 분산은 $\frac{\pi^2}{3}$ 이기 때문에 그 차이를 곱하여 변환해줘야 함

Fisher's Z transformation의 분산 구하기

- 상관관계계수의 분산은 지나치게 한쪽으로 치우쳐져 있어서 $z = \frac{1}{2} \ln \frac{1+r}{1-r}$ 사용함. 여기에 Delta method $\text{Var}(g(X)) \approx [g'(E[X])]^2 \times \text{Var}(X)$ 를 적용
- $Z = g(r) = \frac{1}{2} \ln \frac{1+r}{1-r}$, $g'(r) = \frac{1}{1-\rho^2}$, $\text{Var}(r) \approx \frac{(1-\rho^2)^2}{n-1} \rightarrow \text{Var}(Z) \approx \left(\frac{1}{1-\rho^2} \right)^2 \times \frac{(1-\rho^2)^2}{n-1} = \frac{1}{n-1}$
- 위에서 유도한 $\frac{1}{n-1}$ 은 매우 훌륭한 근사치이지만, 델타 방법의 1차 근사는 r 의 분포가 완벽히 대칭적이지 않은 점이나 다른 고차항의 효과를 충분히 반영하지 못함. 그래서 2차 Taylor 항 등을 포함하여 보정한 결과, $\frac{\rho}{2(n-1)}$ 정도의 편향이 발견되어 이를 반영한 $\frac{1}{n-3}$ 을 표준공식으로 사용함

10 생존분석 데이터

10.1 Hazard Ratio

Cox Proportional Hazard model

- 현실세계의 실제 생존곡선은 불규칙한 형태라서 통계분석, 비교분석이 어려움 → 어떤 이벤트가 발생할 위험율이 시간에 따라서 변하지 않고 일정하다고 가정함
- Cox model : $h(t|X) = h_0(t) \times \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)$
- Hazard ratio의 Log 값을 취하면 지수는 일반적인 1차선형 방정식이므로 두 그룹간의 차이인 HR의 Log 값은 Standard Mean Difference와 같게 됨
- Randomized clinical Trial에서 control group과 experimental group의 HR 차이의 log 값을 평균 효과크기로 보고 meta-analysis 가 가능함. Standard error는 발표된 HR 95% Confidence Interval(1.96σ)로 구할 수 있음
- Sample file

10.2 Material

Article sources for meta-analysis : randomized clinical trials ICI neoadjuvant therapy for NSCLC




표 1:

Source	control	experimental
Forde et al, 2022; CheckMate 816 [1]	PBC, surgery	Nivolumab, 360 mg, plus PBC, surgery
Heymach et al, 2023; AEGEAN [2]	Placebo plus PBC, surgery, and placebo	Durvalumab, 1500 mg, plus PBC, surgery, and durvalumab
Lei et al, 2023; TD-FOREKNOW [3]	Platinum based chemotherapy with nab-paclitaxel , surgery	Camrelizumab, 200 mg, every 3 wk for 3 cycles plus PBC plus nab-paclitaxel, surgery
Zhang et al, 2021; Neotorch [4]	Placebo plus PBC, surgery, placebo plus PBC, and then placebo	Toripalimab, 240 mg, every 3 wk plus PBC , surgery, toripalimab, 240 mg, every 3 wk plus PBC, and toripalimab, 240 mg
Provencio et al, 2023; NADIM II [5]	PBC, surgery, and observation	Nivolumab, 360 mg, plus PBC, surgery, and nivolumab, 480 mg


Continued on next page

표 1: (Continued)

Wakelee et al, 2023; KEYNOTE-671 [6]	Placebo plus PBC, surgery, and placebo	Pembrolizumab, 200 mg, plus PBC, surgery, and pembrolizumab, 200 mg
Cascone et al, 2023; CheckMate 77T [7]	Placebo plus PBC, surgery, and placebo	Nivolumab, 360 mg, plus PBC, surgery, and nivolumab, 480 mg
Yue et al, 2023; RATIONALE-315 [8]	Placebo plus PBC, surgery, and placebo	Tislelizumab, 200 mg, plus PBC, surgery, and tislelizumab, 400 mg


10.3 Risk of Bias

		Risk of bias domains				
		D1	D2	D3	D4	D5
Study	RATION al.	+	+	-	+	+
	Chen al.	+	+	-	+	+
	TD-FOH et al.	+	X	X	X	-
	et al.	+	+	-	+	-
	et al.	+	+	-	+	-
	et al.	+	+	-	+	-
	et al.	+	+	-	+	-
	et al.	+	+	-	+	-
		D1: D1	D2: D2	D3: D3	D4: D4	D5: D5
		Judgement				
		+ Low				
		- Unclear				
		X High				




Study	HR	CI.low	CI.high	logse
Forde et al. [1] 2022	0.63	0.43	0.91	0.3748297
Heymach et al.[2] 2023	0.68	0.53	0.88	0.2535225
Lei et al. [3] 2023	0.52	0.21	1.29	0.9076450
Zhang et al.[4] 2021	0.40	0.28	0.57	0.3554234
Provencio et al.[5] 2023	0.47	0.25	0.88	0.6292305
Wakelee et al. [6] 2023	0.58	0.46	0.72	0.2240124
Cascone et al.[7]2023	0.58	0.42	0.81	0.3283898

10.4 Forest plot



10.5 Publication Bias



10.6 Subgroup analysis

위의 논문들은 Subgroup data를 가지고 있는데 PD-L1 값이 negative, low, high 인 3개의 그룹으로 환자군을 분류하여 생존률을 비교하였다. 이렇게 3개의 그룹의 생존률의 차이를 알아보기 위하여 subgroup meta-analysis 시행


표 2:

Study	HR	CI.low	CI.high	group	author	year	citation	studylab
Forde et al. 2022	0.85	0.54	1.32	PD-L1 negative	Forde	2022	1	CheckMate 816
Heymach et al. 2023	0.76	0.49	1.17	PD-L1 negative	Heymach	2023	2	AEGEAN
Zhang et al. 2021	0.59	0.33	1.03	PD-L1 negative	Zhang	2021	4	Neotorch
Wakelee et al. 2023	0.77	0.55	1.07	PD-L1 negative	Wakelee	2023	6	Keynote 671
Cascone et al. 2023	0.73	0.47	1.15	PD-L1 negative	Cascone	2023	7	CheckMate 77T
Forde et al. 2022	0.41	0.24	0.70	PD-L1 low	Forde	2022	1	CheckMate 816
Heymach et al. 2023	0.70	0.46	1.05	PD-L1 low	Heymach	2023	2	AEGEAN

Continued on next page

표 2: (Continued)

Zhang et al. 2021	0.31	0.20	0.48	PD-L1 low	Zhang	2021	4	Neotorch
Wakelee et al. 2023	0.51	0.34	0.75	PD-L1 low	Wakelee	2023	6	Keynote 671
Cascone et al 2023	0.76	0.46	1.25	PD-L1 low	Cascone	2023	7	CheckMate 77T
Forde et al. 2022	0.24	0.10	0.61	PD-L1 high	Forde	2022	1	CheckMate 816
Heymach et al. 2023	0.60	0.35	1.01	PD-L1 high	Heymach	2023	2	AEGEAN
Wakelee et al. 2023	0.42	0.28	0.65	PD-L1 high	Zhang	2021	4	Neotorch
Cascone et al 2023	0.26	0.12	0.55	PD-L1 high	Wakelee	2023	6	Keynote 671



Summary of analysis

Number of studies: $k = 14$

HR	95%-CI	z t	p-value
Fixed effect model	0.58 (0.51 to 0.65)	-8.65	5.01e-18
Random effects model (HK-IQ)	0.56 (0.45 to 0.69)	-5.74	6.87e-05
Prediction interval	(0.30 to 1.03)		

Quantifying heterogeneity (with 95%-CIs):

$\tau^2 = 0.07$; $\tau = 0.27$; $I^2 = 56\%$ (20% to 76%); $H = 1.51$ (1.12 to 2.04)

Test of heterogeneity:

Q	d.f.	p-value
29.62	13	5.3356e-03

Test for subgroup differences (fixed effect model):

	Q	d.f.	p-value
Between groups	13.80	2	1.0094e-03
Within groups	15.83	11	1.4771e-01

Test for subgroup differences (random effects model (HK-IQ)):

Q d.f. p-value

Between groups 10.26 2 5.9058e-03

Details of meta-analysis methods:

- Inverse variance method
- Restricted maximum-likelihood estimator for τ^2
- Calculation of I^2 based on Q
- Hartung-Knapp adjustment for random effects model (df = 13) (with ad hoc correction)
- Prediction interval based on t-distribution (df = 13)

11 Network meta-analysis


11.1 Introduction

네트워크 메타분석의 형태


- 전통적 메타분석의 한계 : 기본적으로 특정한 치료법에 대해 임상실험을 해서 비교한 효과크기를 종합하는 것이지만 단 하나의 '확정적인' 치료법만 있는 것이 아니라 여러 가지가 존재하여, 특정 적응증에 대해 가장 효과적인 치료법이 무엇인지 알아내는 것이 더 중요
- 두 치료법 간의 충분한 직접 비교(head-to-head comparison) 연구가 필요하지만 '상대적으로 덜 효과적인' 대조군 대신 두 치료법의 효과를 직접 비교한 연구가 거의 없거나 아예 없는 것이 일반적
- 다수의 치료를 가진 여러 연구들의 효과크기를 종합하는 방법 : 직접적인 증거 뿐만 아니라 간접적인 증거도 종합 → 이러한 간접 비교를 통합하여 여러 중재법의 효과를 동시에 비교할 수 있게 해준다.
- 지난 10년간 바이오-의료 분야 및 다른 학문 분야의 응용 연구자들 사이에서 점점 더 많이 채택되고 있지만 이질성(heterogeneity)과 네트워크 비일관성(network inconsistency) 문제가 어려움

직접 증거와 간접증거


- 치료법 A의 효과를 대조군 B와 비교한다고 가정하면 이것을 그래프로 다음과 같이 표현할 수 있다.



- 이제 또 다른 연구 j 에서 데이터를 얻었다고 가정하고 대조군으로 B를 사용했지만, A 대신 다른 치료법 C를 사용해서 그 효과크기를 계산함 $\rightarrow$ A와 B를 비교하는 $\hat{\theta}_{i,A,B}$ 와 C와 B를 비교하는 $\hat{\theta}_{j,C,B}$ 가 같이 존재



- 직접적으로 연결된 것은 $B \rightarrow A, B \rightarrow C$ 이지만 $A \rightarrow C$ 의 연결도 간접적으로 존재함



새롭게 등장하는 간접적인 효과크기 $\hat{\theta}_{A,C}^{indirect}$ 는 다음과 같이 계산됨

$$\hat{\theta}_{A,C}^{indirect} = \hat{\theta}_{B,A}^{direct} - \hat{\theta}_{B,C}^{direct}$$

이 단계는 네트워크 메타분석의 핵심적인 구성 요소이다. 위 수식을 통해, 임상시험에서 직접 평가되지 않은 비교에 대해서도 효과 크기를 추정할 수 있다.

- 네트워크 메타분석의 이점은 하나의 분석으로 관련된 연구들로부터 가용한 모든 정보를 통합할 수 있고, 네트워크 내의 간접적 증거를 통합할 수 있으며, 모든 가정이 충족되고 결과가 충분히 결정적이라면, 연구 대상 집단에 어떤 유형의 치료법이 더 선호될 수 있는지 추론할 수 있다는 점이다.
- 간접증거의 한계점이 있는데 그것은 분산의 크기가 직접 증거의 분산을 더한 값이 된다는 점이다.

$$\text{Var}(\hat{\theta}_{A,C}^{indirect}) = \text{Var}(\hat{\theta}_{B,A}^{direct}) + \text{Var}(\hat{\theta}_{B,C}^{direct})$$

추이성과 일관성

- NMA의 주요 논란의 대상: 네트워크내의 시험조건에서는 참가자가 무작위로 선택되지 않았다는 점
- 추이성(Transitivity) 가정: 직접적 증거(예: A-B 및 C-B 비교)를 결합하여 관련된 다른 비교(예: A-C)에 대한 간접적 증거를 만들 수 있다는 것
- 추이성 가정은 교환 가능성(exchangeability)의 개념과 관련이 있다. 교환 가능성 가정은 어떤 비교 i 의 각 실제 효과 크기 θ_i 가 실제 효과 크기들의 분포에서 무작위적이고 독립적인 추출의 결과라는 것이다. 그렇기 때문에 같은 모집단에서 비교하지 않아도 무작위-효과 모델이 성립할 수 있다.
- 네트워크 메타분석을 K개의 시험 집합으로 하고 여기에는 모든 종류의 치료비교가(예: A-B, A-C, B-C 등) 포함되어 있다고 하면, 특정한 비교 예를 들어 A-B 비교의 효과가 시험들 사이에서 교환 가능하다는 것. 일부 시험에서는 누락되어 있어도 상관없이 다른 시험들과 교환가능하다는 가정
- 추이성 가정은 시험들 전반에 걸쳐 공변량이나 다른 효과 조절 변수(예: 연구 대상 인구의 연령대, 치료 강도)가 고르게 분포되어 있지 않을 때 위반될 수 있다. 추이성 자체는 통계적으로 검정할 수 없지만, 인구, 방법론, 대상 조건이 가능한 한 유사한 연구들만 포함함으로써 이 가정을 위반할 위험을 줄일 수 있다

- 추이성의 통계적 표현을 일관성(consistency)이라고 하며, 이것이 결여된 상태를 비일관성(inconsistency)이라고 한다. 일관성이란 직접적 증거에 기반한 비교(예: A-B)의 상대적 효과가 간접적 증거에 기반한 것과 다르지 않음을 의미

$$\hat{\theta}_{A,B}^{\text{indirect}} = \hat{\theta}_{A,B}^{\text{direct}}$$

- 네트워크 메타분석 모델에서 비일관성을 진단하기 위해 네트워크 히트 플롯(net heat plot)과 노드 분리법(node splitting)을 포함한 여러 방법이 제안되었다.

11.2 기본적인 계산방법

네트워크 메타분석의 공식 (*Frequentist Method*)

- 네트워크 메타분석의 방법은 크게 두가지가 있다. 빈도주의자 (Frequentist) 방법과 베이지언 계층화 방법 (Bayesian hierarchical model). 이중에서 베이지언 방법이 유연하지만 빈도주의자의 공식의 기본 원리가 이해가 쉬움
- K 개의 시험을 검토하여 연구에 포함된 총 치료 비교 수를 센다. 이 쌍 비교의 수를 m 으로 나타낸다. n 가지의 치료법이 존재할 경우 비교해야할 쌍의 갯수는 $nC_2 = \frac{n(n-1)}{2}$ 가 된다.
- 모든 효과 크기를 벡터 $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m)$ 형태로 수집한다. 이 효과크기 벡터가 어떻게 생성되었는지를 설명하는 모델이 필요하다.

$$\hat{\theta} = X\theta_{\text{treat}} + \epsilon$$

- X 는 $m \times n$ 의 디자인 행렬로 열은 서로 다른 치료법의 갯수 n 을 나타내고 행은 치료 비교 m 을 나타낸다. 이 행렬에서 치료 비교는 같은 행에 있는 1과 -1로 정의되며, 이때 열의 위치는 비교되는 치료법에 해당한다. 비교대상이 아닌 열의 값은 0으로 표기함.
- θ_{treat} 네트워크에 있는 n 개의 고유한 치료법의 실제(true) 효과를 의미함. 이 벡터는 우리 네트워크에서 어떤 치료법이 가장 효과적인지 결정할 수 있게 해주므로, 네트워크 메타분석 모델이 추정해야 할 대상

- ϵ : 모든 비교의 표본추출 오차(sampling error) ϵ_m 을 포함하는 벡터. 각 비교의 표본추출 오차는 평균이 0이고 분산이 σ_m^2 인 가우스 정규분포로부터의 무작위 추출이라고 가정 $\epsilon_m \sim N(0, \sigma_m^2)$

Example

- 위의 수식을 이해하기 쉽게 하기 위해서 예를 들면..
- A-B, A-C, A-D, B-C, B-D 의 5개의 시험이 있다고 가정하고 $\hat{\theta} = (\hat{\theta}_{1,A,B}, \hat{\theta}_{2,A,C}, \hat{\theta}_{3,A,D}, \hat{\theta}_{4,B,C}, \hat{\theta}_{5,B,D})^\top$ 이라고 놓는다. 우리의 목표는 실제 효과크기 $\theta_{\text{treat}} = (\theta_A, \theta_B, \theta_C, \theta_D)^\top$ 를 구하는 것이다.

$$\hat{\theta} = X\theta_{\text{treat}} + \epsilon$$

$$\begin{bmatrix} \hat{\theta}_{1,A,B} \\ \hat{\theta}_{2,A,C} \\ \hat{\theta}_{3,A,D} \\ \hat{\theta}_{4,B,C} \\ \hat{\theta}_{5,B,D} \end{bmatrix} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ 1 & 0 & -1 & 0 \\ 1 & 0 & 0 & -1 \\ 0 & 1 & -1 & 0 \\ 0 & 1 & 0 & -1 \end{bmatrix} \begin{bmatrix} \theta_A \\ \theta_B \\ \theta_C \\ \theta_D \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \epsilon_4 \\ \epsilon_5 \end{bmatrix}$$

- 지금 이 모델은 과대모수화(overparameterized)되어 있다. 즉, 주어진 정보에 비해 우리 모델에서 추정해야 할 매개변수 θ_{treat} 가 너무 많다. $n - 1$ 개의 독립적인 치료 비교만 존재할 수 있지만, 항상 θ_{treat} 에서 n 개 치료법의 실제 효과를 추정해야 한다. 따라서 이 행렬 X 가 완전 계수를 갖지 않는다는 사실은 이 행렬이 가역적(invertible), 즉 역행렬을 가질 수 없다는 것을 의미하고 최소제곱법(least squares approach)을 사용하여 θ_{treat} 를 직접 추정할 수 없다.
- 바로 이 지점에서 netmeta 에 구현된 그래프 이론적(graph theoretical) 접근법이 해결책을 제공

Moore-Penrose pseudoinverse matrix

- 과대모수화(overparameterized)되어 있는 행렬의 문제점을 해결하기 위하여 $n \times n$ Laplacian matrix를 정의한다.

$$\mathbf{L} = \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

여기서 $\mathbf{W}$ 는 $m \times m$ diagonal matrix 이고 각각의 대각원소는 $(1/s_1^2, 1/s_2^2, \dots, 1/s_m^2)$: 역분산 가중치이다.

- 이때 Laplacian matrix은 $n - 1$ rank로 $\mathbf{L}^{-1}$ 역행렬이 존재하지 않으므로 다음과 같은 $\mathbf{L}^+$ 를 정의한다.

$$\mathbf{L}^+ = (\mathbf{L} - \mathbf{J}/n)^{-1} + \mathbf{J}/n, \quad \mathbf{J} = n \times n \text{ matrix whose elements are all } 1$$

- $\mathbf{L}^+$ 를 얻게 되면 다음과 같이 θ_{treat} 를 계산할 수 있다.


$$\theta_{\text{treat}} = \mathbf{X} \mathbf{L}^+ \mathbf{X}^\top \mathbf{W} (\hat{\theta} - \epsilon) = \mathbf{H} (\hat{\theta} - \epsilon), \quad \mathbf{H}: \text{called hat matrix}$$

- 분산-공분산 행렬은 $\mathbf{X} \mathbf{L}^+ \mathbf{X}^\top$ 으로 계산이 가능하고, 랜덤효과크기도 분산 s_i^2 대신에 $s_i^2 + \tau^2$ 를 사용하면 된다.
- Laplacian matrix는 그래프의 구조와 연결성에 대한 정보를 담고 있는 행렬로서 그래프의 각 꼭짓점(node)이 어떻게 연결되어 있는지를 수학적으로 표현함.

11.3 네트워크 메타분석 케이스

데이터 특성

- 급성 우울증 치료를 위해 어떤 인지행동치료 제공 형태가 가장 효과적이고 수용 가능한가? 에 대한 답을 하기 위해 15,191 명의 환자가 참여한 155개 임상시험에 대한 네트워크 메타분석
- cognitive behavior therapy 인지행동치료는 우울증에 효과가 있으며 개인치료로 개발되어 있으나, group, telephone-administered, and self-help therapy 등의 형태로도 접근 가능함. 네트워크 메타분석을 통해서 다양한 CBT 제공 형태의 상대적 효과성을 평가
- 기간 : 1966년 1월 1일부터 2018년 1월 1일까지
- Treatment group : individual, group, telephone, guided self-help (administered through the internet or other media, such as a book), and unguided self-help (internet-based or not)
- Control group : waiting list, care as usual, and pill placebo
- Outcome : the severity of depression : Hamilton Rating Scale ; Beck Depression Inventory I or II; another clinician-rated instrument etc.



네트워크 그래프


	Care As Usual	Group	Guided Self-Help	Telephone	Unguided Self-Help	Waitlist
Group	21	0	5	0	1	18
Guided Self-Help	8	0	0	0	5	36
Individual	30	7	4	4	0	18
Telephone	6	0	0	0	0	1
Unguided Self-Help	9	0	0	0	0	11


효과크기 테이블

	cau	grp	gsh	ind	tel	ush	wlc
cau	0.00	0.58	0.39	0.64	0.51	0.13	-0.26
grp	-0.58	0.00	-0.18	0.06	-0.06	-0.45	-0.84
gsh	-0.39	0.18	0.00	0.25	0.12	-0.26	-0.65
ind	-0.64	-0.06	-0.25	0.00	-0.13	-0.51	-0.90
tel	-0.51	0.06	-0.12	0.13	0.00	-0.38	-0.77
ush	-0.13	0.45	0.26	0.51	0.38	0.00	-0.39
wlc	0.26	0.84	0.65	0.90	0.77	0.39	0.00

Net league table

	cau	grp	gsh	ind	tel	ush	wlc
cau	cau	0.37 [0.30; 0.44]	0.57 [0.43; 0.71]	0.70 [0.65; 0.76]	0.75 [0.59; 0.91]	0.19 [0.05; 0.34]	.
grp	0.58 [0.52; 0.63]	grp	-0.23 [-0.36; -0.11]	0.10 [-0.10; 0.30]	.	-0.67 [-0.89; -0.46]	-0.98 [-1.05; -0.91]
gsh	0.39 [0.33; 0.46]	-0.18 [-0.24; -0.12]	gsh	0.11 [-0.26; 0.47]	.	-0.40 [-0.56; -0.24]	-0.61 [-0.67; -0.56]
ind	0.64 [0.59; 0.69]	0.06 [0.00; 0.13]	0.25 [0.18; 0.31]	ind	-0.19 [-0.32; -0.05]	.	-0.76 [-0.84; -0.67]
tel	0.51 [0.42; 0.61]	-0.06 [-0.17; 0.04]	0.12 [0.01; 0.22]	-0.13 [-0.22; -0.03]	tel	.	-0.56 [-0.75; -0.37]
ush	0.13 [0.04; 0.21]	-0.45 [-0.53; -0.36]	-0.26 [-0.35; -0.18]	-0.51 [-0.60; -0.42]	-0.38 [-0.51; -0.26]	ush	-0.52 [-0.65; -0.39]
wlc	-0.26 [-0.32; -0.20]	-0.84 [-0.89; -0.78]	-0.65 [-0.70; -0.60]	-0.90 [-0.96; -0.84]	-0.77 [-0.87; -0.67]	-0.39 [-0.47; -0.31]	wlc






네트워크 히트 플롯(Net Heat Plot) 해석하기

회색 상자는 특정 치료 비교(열)가 다른 치료 비교(행)의 추정치에 얼마나 중요한지를 나타낸다. 상자가 클수록 그 비교는 더 중요함

일반적으로 히트맵의 대각선에 있는 상자들이 큰 것을 발견할 수 있는데, 이는 직접적 증거가 사용되었음을 의미하기 때문

색상 배경은 특정 열의 설계(비교)에서 기인하는 비일관성이 해당 행의 설계(비교)에 얼마나 영향을 미치는지를 나타낸다


필드 색상은 짙은 빨간색(강한 비일관성을 나타냄)부터 파란색(해당 열의 증거가 행의 증거를 지지함을 나타냄)까지



전 페이지 결과들은 고정 효과 모델(fixed-effect model)에 기반

이질성과 설계 비일관성이 너무 크기 때문에 고정 효과 모델을 사용하는 것이 적절하지 않았음

임의 효과 모델(random-effects model)을 가정했을 때 네트워크의 비일관성이 상당히 감소하는 것을 볼 수 있다. 따라서 임의 효과 모델이 더 적합하다고 결론




네트워크의 일관성(consistency)을 확인하는 또 다른 방법은 노드 분리법(net splitting)이다.

이 방법은 네트워크 추정치를 직접적 증거의 기여분과 간접적 증거의 기여분으로 분리하는 것: 이를 통해 네트워크 내 개별 비교 추정치에서 발생하는 비일관성을 확인할 수 있다.

결과에서 제시되는 가장 중요한 정보는 직접적 증거와 간접적 증거에 기반한 효과 추정치 간의 차이(Diff)와, 이 차이가 유의미한지 여부(p-값 열로 표시)

만약 차이가 $p < 0.05$ 라면, 직접 추정치와 간접 추정치 사이에 유의미한 불일치, 즉 비일관성이 존재한다는 의미

결과를 보면, (고정 효과 모델을 사용했을 때) 직접적 증거와 간접적 증거 사이에 유의미한 비일관성을 보이는 비교가 실제로 많다는 것을 알 수 있다.



비교-보정 깔때기 그림 (Comparison-adjusted funnel plot) 은 네트워크 메타분석에서 출판 편향의 위험을 평가하기 위해 제안되었으며, 일부 상황에서 사용될 수 있다.

추이성 가정이 성립하려면, 서로 다른 직접 비교를 수행하는 연구들이 비교되는 치료법 외의 모든 측면에서 충분히 유사해야 한다.

효과 크기에 대한 신뢰도 vs. 치료 순위에 대한 신뢰도
 순위 측정은 증거 네트워크 전체에 대한 추론을 포함하는 반면, 쌍 비교 효과 크기는 특정 직접 및 간접 증거들의 복잡한 가중 평균에서 파생되며, 보통 직접적 증거가 더 많은 가중치를 차지한다.

11.4 Baysian inference

베이즈 정리

- 베이저안 통계학의 기초는 토머스 베이즈 목사(1701-1761)가 처음 공식화한 베이즈 정리


$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

- $P(B|A)$ 부분은 우도(likelihood): A가 사실이거나 발생했을 때의 사건 B의 확률
- $P(A)$ 는 A가 발생할 사전 확률(prior probability)
- $P(A|B)$ 는 사후 확률(posterior probability), 즉 B가 주어졌을 때의 A의 확률
- $P(B)$ 는 고정된 상수이므로, $P(A|B) \approx P(B|A) \times P(A)$
- 단순히 A의 확률에 대해 가지고 있는 사전 정보를, A가 발생했을 때 B의 우도와 결합하여, 우리의 사후(posterior) 또는 조정된 A의 확률 $P(A|B)$ 를 생성한다. 여기서 핵심은 이전 지식을 고려할 때 A의 확률에 대한 '더 나은'(사후) 추정치를 생성할 수 있다는 점이고, 이 지식이 바로 가정된 A의 (사전) 확률

- A와 B를 두 변수의 확률 분포로 생각할 수도 있다. A가 정규분포를 따르는 확률 변수라고 상상하면, 이 분포는 우리가 θ 로 표기하는 모수(parameter) 집합으로 특징지어질 수 있다. A가 정규분포를 따르므로, θ 는 두 가지 요소, 즉 A의 실제 평균 μ 와 분산 σ^2 를 포함한다. 이 모수 θ 가 우리가 실제로 추정하고자 하는 것이다.
- B에 대해서는 θ 를 추정하는 데 사용하고 싶은 실제 데이터를 벡터 Y에 저장했다고 가정하면 우리의 관찰된 데이터 또한 $P(Y)$ 로 표현되는 정규분포를 따른다.

$$P(\theta|Y) \approx P(Y|\theta) \times P(\theta)$$

- 이 새로운 방정식은 $P(\theta)$ 의 가정된 사전 분포(prior distribution)인 $P(\theta)$ 를 포함하는데 이 사전 분포는 우리의 이전 지식이나, 심지어 θ 가 어떤 모습일지에 대한 직관에 기반하여 우리가 사전에(a priori) 정의할 수 있다. 모수 θ 가 주어졌을 때 수집된 데이터의 확률인 우도 분포(likelihood distribution) $P(Y|\theta)$ 와 함께, 우리는 사후 분포(posterior distribution) $P(\theta|Y)$ 를 추정할 수 있다. 이 사후 분포는 관찰된 데이터와 우리의 사전 지식을 모두 고려했을 때의 θ 에 대한 우리의 추정치를 나타낸다.
- 베이지안 추론의 특징 : 사후 결과 역시 단일한 '참' 값이 아니라 여전히 분포라는 것
실제 모수 값에 대한 우리의 믿음(beliefs)을 나타낸다는 의미에서 주관적이기도 해서 베이지안 통계학에서는 추정치 주변의 신뢰구간(confidence interval)을 계산하는 대신 신용구간(credible interval, CrI)을 계산



앞에서 설명한 세 가지 분포 시각화

베이저안 접근법의 또 다른 장점은 모수(parameter)가 다른 종류의 (더 복잡한) 분포도 모델링할 수 있다는 점이지만, 단점은, 수집된 데이터로부터 (결합) 분포를 생성하는 데 계산이 많이 필요하다는 점. → 사후 분포 (posterior distribution)를 생성하기 위해, 깁스 샘플링 (Gibbs sampling) 알고리즘과 같은 특별한 마르코프 연쇄 몬테카를로 (Markov Chain Monte Carlo, MCMC) 시뮬레이션 절차가 사용된다.

베이지안 고정효과모델


- k 개의 연구에 대해서 각 연구에 대해 관찰된 효과 크기 $\hat{\theta}_k$ 를 계산하면 고정 효과 모델을 다음과 같이 정의할 수 있다

$$\hat{\theta}_k \sim N(\theta, \sigma_k^2)$$

- 이 공식은 우리 효과 크기들의 우도(likelihood), 즉 $P(Y | \theta)$ 부분을 표현하며, 이들이 정규분포를 따른다고 가정한다. 각 효과 크기가 동일한 분포에서 추출된 표본이라고 가정하며, 이 분포의 평균은 실제 효과 크기 θ 이고 분산은 σ_k^2
- 고정 효과 모델에서는 실제 효과 크기가 모든 연구에서 동일하다고 가정하므로, θ 는 서로 다른 연구 k 와 그 관찰된 효과 크기 $\hat{\theta}_k$ 에 대해 동일하게 유지된다.
- 베이지안 모델의 흥미로운 측면은, 실제 효과 θ 가 알려지지 않았음에도 불구하고 그것에 대한 사전 분포(prior distribution)를 정의할 수 있다는 점.

예제

- 똑같은 데이터를 이용해서 Bayesian 접근법으로 분석
- 빈도주의적 분석에서 상당한 이질성과 비일관성이 나타났으므로, linearModel = "random"을 사용
- 연속형 결과 데이터(즉, SMD)를 기반으로 한 효과 크기를 다루고 있으므로, "항등(identity)" 연결 함수와 함께 "정규(normal)" 우도를 가정
- MCMC 시뮬레이션을 적용한다. : 이 모델의 모수(parameter)의 사후 분포를 추정하고, 이를 통해 네트워크 메타분석의 결과를 생성할 수 있게 해줌
- MCMC 과정은 모델 모수의 정확한 추정치를 얻을 수 있을 만큼 충분히 오래 실행해야 한다.
- 번인 (Burn-in) 단계 (n.adapt): 결과가 부정확하기 때문에 폐기되는 초기 번인(burn-in) 반복 횟수를 정의
- 시뮬레이션 단계 (n.iter): 실제로 모델 모수를 추정하는 데 사용되는 실제 시뮬레이션 반복 횟수를 명시
- 시뮬레이션이 알고리즘의 수렴(convergence)으로 이어졌는지 확인하기 위해 trace plot을 만드는데 이것은 모든 반복에 걸쳐 각 치료 비교에 대한 일종의 time series 를 제공함.



```
> mcmc1 = mtc.run(model, n.adapt = 50,
```

```
> n.iter = 1000, thin = 10)
```

```
burn-in = 50, iteration = 1000
```


mcmc2의 플롯에서는 훨씬 더 빠른 상하 변동을 보이지만, 실제 장기적인 추세는 없어서 설정이 더 적절하다. mcmc2의 밀도함수도 정규분포에 더 가깝게 부드러움

```
> mcmc2 = mtc.run(model, n.adapt = 5000,
```

```
> n.iter = 1e5, thin = 10)
```

```
burn-in = 5000, iteration = 105
```

Gelman-Rubin plot : 잠재적 축소 요인(Potential Scale Reduction Factor, PSRF) - 각 연쇄(chain) 내의 변동과 연쇄 간의 변동을 비교하고, 이 둘이 시간에 따라 어떻게 변하는지를 나타냄. PSRF는 반복 횟수가 증가함에 따라 점차 1에 가까워져야 하며, 최종적으로는 적어도 1.05 미만이어야 한다.



네트워크 메타-회귀분석(*network meta-regression*)

- 베이지안 분석의 장점중 하나는 네트워크 메타-회귀분석(network meta-regression) 가능하다는 점
- 이 기능을 사용하여 특정 연구 특성이 우리 네트워크에서 발견된 효과 크기의 크기에 영향을 미치는지 확인할 수 있고, 또한 비일관성을 설명할 수 있는 변수를 확인하는 데 유용한 도구가 될 수 있다.

12 결론

메타분석의 의미

- 의학에서 메타분석은 개별 연구 결과들을 종합하여 가장 높은 수준의 과학적 근거를 제시하기 때문에 매우 중요하고 의사들이나 정책 입안자들이 수많은 연구 결과 속에서 헛갈리지 않고, 가장 신뢰할 수 있는 정보를 바탕으로 최선의 결정을 내리도록 돕는 핵심적인 역할을 한다.
- 메타분석은 관련된 여러 연구 결과를 통계적으로 통합하여 전체적인 경향과 효과 크기를 분석하며 이를 통해 개별 연구의 한계나 편향을 넘어선, 가장 객관적이고 신뢰성 높은 결론을 도출한다.
- 네트워크 메타분석은 'A와 C의 비교 연구'와 'B와 C의 비교 연구'가 있다면, 공통 대조군인 C를 매개로 하여 A와 B의 효과를 간접적으로 비교할 수 있다. 모든 치료법을 일대일로 비교한 연구는 현실적으로 부족한데, 이런 직접적인 비교 연구가 부족한 상황에서도 과학적 근거에 기반한 의사결정을 가능하게 한다.

참고 문헌

- [1] P. M. Forde, J. Spicer, S. Lu, M. Provencio, T. Mitsudomi, M. M. Awad, E. Felip, S. R. Broderick, J. R. Brahmer, S. J. Swanson, K. Kerr, C. Wang, T.-E. Ciuleanu, G. B. Saylor, F. Tanaka, H. Ito, K.-N. Chen, M. Liberman, E. E. Vokes, J. M. Taube, C. Dorange, J. Cai, J. Fiore, A. Jarkowski, D. Balli, M. Sausen, D. Pandya, C. Y. Calvet, and N. Girard, “Neoadjuvant nivolumab plus chemotherapy in resectable lung cancer,” *The New England journal of medicine*, vol. 386, pp. 1973–1985, May 2022.
- [2] J. V. Heymach, D. Harpole, T. Mitsudomi, J. M. Taube, G. Galffy, M. Hochmair, T. Winder, R. Zukov, G. Garbaos,

- S. Gao, H. Kuroda, G. Ostoros, T. V. Tran, J. You, K.-Y. Lee, L. Antonuzzo, Z. Papai-Szekely, H. Akamatsu, B. Biswas, A. Spira, J. Crawford, H. T. Le, M. Aperghis, G. J. Doherty, H. Mann, T. M. Fouad, and M. Reck, “Perioperative durvalumab for resectable non-small-cell lung cancer,” *The New England journal of medicine*, vol. 389, pp. 1672–1684, Nov 2023.
- [3] J. Lei, J. Zhao, L. Gong, Y. Ni, Y. Zhou, F. Tian, H. Liu, Z. Gu, L. Huang, Q. Lu, X. Wang, J. Sun, E. Yang, T. Wang, D. Zhong, J. Wang, Z. Zhao, Z. Liu, C. Wang, X. Wang, G. Lei, X. Yan, and T. Jiang, “Neoadjuvant camrelizumab plus platinum-based chemotherapy vs chemotherapy alone for chinese patients with resectable stage iiia or iiib (t3n2) non-small cell lung cancer: The td-foreknow randomized clinical trial,” *JAMA oncology*, vol. 9, pp. 1348–1355, Oct 2023.
- [4] Y. Zhang, L. Zeng, X. Zhang, Y. Zhou, B. Zhang, W. Jiang, N. Yang, and C. Zhou, “P15.02 toripalimab and platinum-doublet chemotherapy as neoadjuvant therapy for potentially resectable non-small cell lung cancer,” vol. 16, pp. S1014–S1015.
- [5] M. Provencio, E. Nadal, J. L. González-Larriba, A. Martínez-Martí, R. Bernabé, J. Bosch-Barrera, J. Casal-Rubio, V. Calvo, A. Insa, S. Ponce, N. Reguart, J. de Castro, J. Mosquera, M. Cobo, A. Aguilar, G. L. Vivanco, C. Camps, R. López-Castro, T. Morán, I. Barneto, D. Rodríguez-Abreu, R. Serna-Blasco, R. Benítez, C. A. de la Rosa, R. Palmero, F. Hernando-Trancho, J. Martín-López, A. Cruz-Bermúdez, B. Massuti, and A. Romero, “Perioperative nivolumab and

- chemotherapy in stage iii non-small-cell lung cancer,” *The New England journal of medicine*, vol. 389, pp. 504–513, Aug 2023.
- [6] H. Wakelee, M. Liberman, T. Kato, M. Tsuboi, S.-H. Lee, S. Gao, K.-N. Chen, C. Dooms, M. Majem, E. Eigendorff, G. L. Martinengo, O. Bylicki, D. Rodríguez-Abreu, J. E. Chaft, S. Novello, J. Yang, S. M. Keller, A. Samkari, and J. D. Spicer, “Perioperative pembrolizumab for early-stage non-small-cell lung cancer,” *The New England journal of medicine*, vol. 389, pp. 491–503, Aug 2023.
- [7] T. Cascone, M. Awad, J. Spicer, J. He, S. Lu, B. Sepesi, F. Tanaka, J. Taube, R. Cornelissen, L. Havel, J. Kuzdzal, L. Petruzella, L. Wu, J.-L. Pujol, H. Ito, C. Coronado Erdmann, P. Sathyanarayana, S. Meadows-Shropshire, and M. Provencio Pulla, “LBA1 CheckMate 77T: Phase III study comparing neoadjuvant nivolumab (NIVO) plus chemotherapy (chemo) vs neoadjuvant placebo plus chemo followed by surgery and adjuvant NIVO or placebo for previously untreated, resectable stage II–IIIb NSCLC,” vol. 34, p. S1295.
- [8] D. Yue, W. Wang, H. Liu, Q. Chen, C. Chen, J. Zhang, F. Bai, and C. Wang, “LBA58 Pathological response to neoadjuvant tislelizumab (TIS) plus platinum-doublet (PtDb) chemotherapy (CT) in resectable stage II-IIIa NSCLC patients (pts) in the phase III (Ph3) RATIONALE-315 trial,” vol. 34, p. S1299.